


# TSBIR 实验报告

论文：A Sketch Is Worth a Thousand Words: Image Retrieval with Text and Sketch<sup>[1]</sup>

报告人：唐明强（南方科技大学） 指导老师：邓小明、胡皓翔（中国科学院软件研究所）



**SUSTech** Southern University  
of Science and  
Technology

[1] Sangkloy, P., Jitkrittum, W., Yang, D., & Hays, J. (2022, October). A sketch is worth a thousand words: Image retrieval with text and sketch. In *European conference on computer vision* (pp. 251-267). Cham: Springer Nature Switzerland.




# 目录

1. 论文概述
2. 数据准备
3. 模型训练
4. 结果评价
5. 分析改进



# 1. 论文概述

## (1) 问题定义

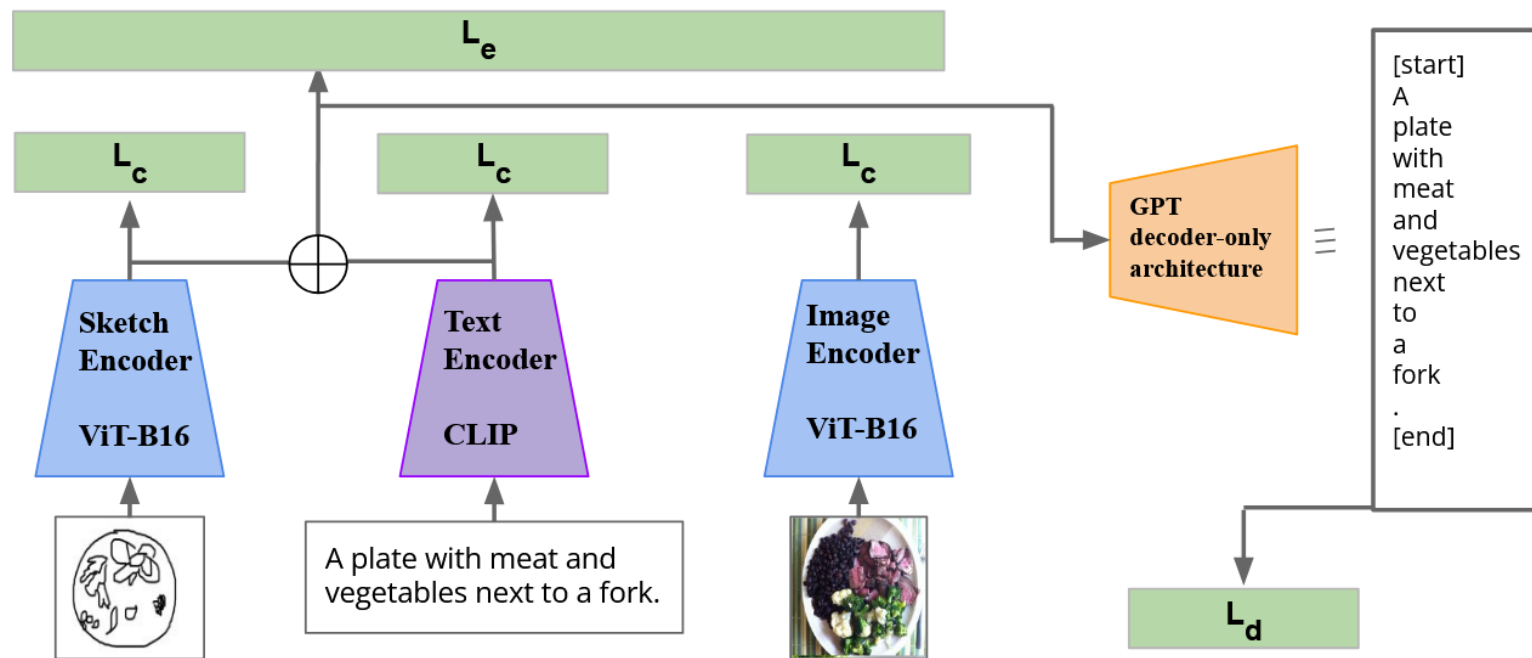


任务目标是在图像库中检索与查询最匹配的真实图像。**文本**提供语义属性，**草图**提供形状和布局线索，二者互补



# 1. 论文概述

## (2) 模型结构



图像与草图共享 ViT-B/16 编码器，文本使用 CLIP Text Encoder。草图和文本通过逐元素平均完成后期融合，并与图库图像计算余弦相似度：

$$\mathbf{q} = \text{Norm} \left( \frac{\mathbf{s} + \mathbf{t}}{2} \right), \quad \text{score}(\mathbf{q}, \mathbf{v}) = \mathbf{q}^T \mathbf{v}$$

多任务训练目标：

$$\mathcal{L}_{\text{base}} = 100\mathcal{L}_e + 10\mathcal{L}_c + \mathcal{L}_d$$

$\mathcal{L}_e$ : CLIP式双向对比损失，对齐查询与目标图像；

$\mathcal{L}_c$ : 多标签 ASL 分类损失，增强物体类别语义；

$\mathcal{L}_d$ : Caption Decoder 交叉熵损失，保留细粒度描述信息。



## 2. 数据准备

### (1)数据集：

- a. COCO 2014 (Karpathy train/val/test 划分)
- b. 原论文提供的 5000 张人工草图 (用于测试)
- c. PhotoSketch 合成的草图 (用于训练)

| 划分         | 图片数     | 文本数     | 草图类型             |
|------------|---------|---------|------------------|
| Train      | 113,287 | 566,747 | PhotoSketch 合成草图 |
| Validation | 5,000   | 25,010  | PhotoSketch 合成草图 |
| Test       | 5,000   | 25,010  | 人工手绘草图           |

### 补充：

- 每张图片有5条文本描述语句
- 总共 90 个 COCO 物体类别
- 训练主要使用 PhotoSketch 合成草图，测试使用人工草图，因此该设置能够检验模型从合成草图到人工草图的泛化能力



## 2. 数据准备

### (2) 数据预处理

为了缓解草图稀疏、变形和不完整带来的影响，采用以下数据增强：

- 图片和草图统一缩放至 224\*224
- 使用 CLIP 均值和方差进行归一化
- 图片和草图分别进行独立仿射增强：
  - -30°~ 30°旋转
  - 最大 30% 平移
  - 尺度、剪切和随机裁剪
- 草图使用 Stroke Dropout，随机删除部分笔画像素

为了使模型同时适应草图、文本和混合检索，训练时使用Query Dropout：

- 80%：草图 + 文本
- 10%：白色草图 + 文本
- 10%：草图 + 空文本



# 3. 模型训练

## 模型初始化

- 基础骨干: OpenAI CLIP ViT-B/16
- 分类头和 Caption Decoder 随机初始化, 并与编码器联合训练

## 训练策略


- 图像与草图共享 ViT-B/16 参数
- 文本使用 CLIP Text Transformer
- 三种模态均映射为 512 维检索特征
- 使用全局唯一图片采样, 避免同一图片的不同 Caption 在 Batch 内互为假负样本
- DDP 训练时通过 all\_gather 扩大全局负样本范围

| 参数            | 实际配置                  |
|---------------|-----------------------|
| GPU           | 2 × NVIDIA L40S 46 GB |
| 分布式训练         | PyTorch DDP, 2 进程     |
| Epoch         | 10                    |
| 全局 Batch Size | 192                   |
| 训练样本/轮        | 566,747               |
| 优化器           | AdamW                 |
| 初始学习率         | $1 \times 10^{-5}$    |
| 最低学习率         | $1 \times 10^{-6}$    |
| Warmup        | 1,000 steps           |
| 调度策略          | Cosine Decay          |
| 混合精度          | BF16                  |
| 梯度检查点         | 关闭                    |
| 梯度裁剪          | 1.0                   |
| 峰值显存          | 约 25.49 GiB/卡         |
| 训练时间          | 约 7 小时 34 分钟          |



# 3. 模型训练

TASK-former 10-epoch loss curves (rolling mean: 15 logged points)



| Epoch | 总损失    | 对比损失   | 分类损失   | Decoder 损失 |
|-------|--------|--------|--------|------------|
| 1     | 93.017 | 0.6316 | 2.3003 | 6.8563     |
| 2     | 50.775 | 0.2891 | 1.7109 | 4.7555     |
| 5     | 32.542 | 0.1528 | 1.3575 | 3.6896     |
| 8     | 26.338 | 0.1021 | 1.2723 | 3.4021     |
| 10    | 23.842 | 0.0807 | 1.2437 | 3.3376     |

## 分析:

- ① 总损失从 93.017 降至 23.842，对比损失从 0.6316 降至 0.0807，说明检索特征空间已明显收敛
- ② 分类和 Decoder 损失下降较慢，说明语义分类与描述生成仍是较难的辅助目标





## 4. 结果评价

| 检索方式 | 查询数    | R@1           | R@5           | R@10          | MRR           |
|------|--------|---------------|---------------|---------------|---------------|
| 草图检索 | 5,000  | 12.60%        | 24.38%        | 31.66%        | 18.98%        |
| 文本检索 | 25,010 | 43.63%        | 72.26%        | 81.92%        | 56.60%        |
| 混合检索 | 25,010 | <b>49.27%</b> | <b>75.86%</b> | <b>85.07%</b> | <b>61.26%</b> |

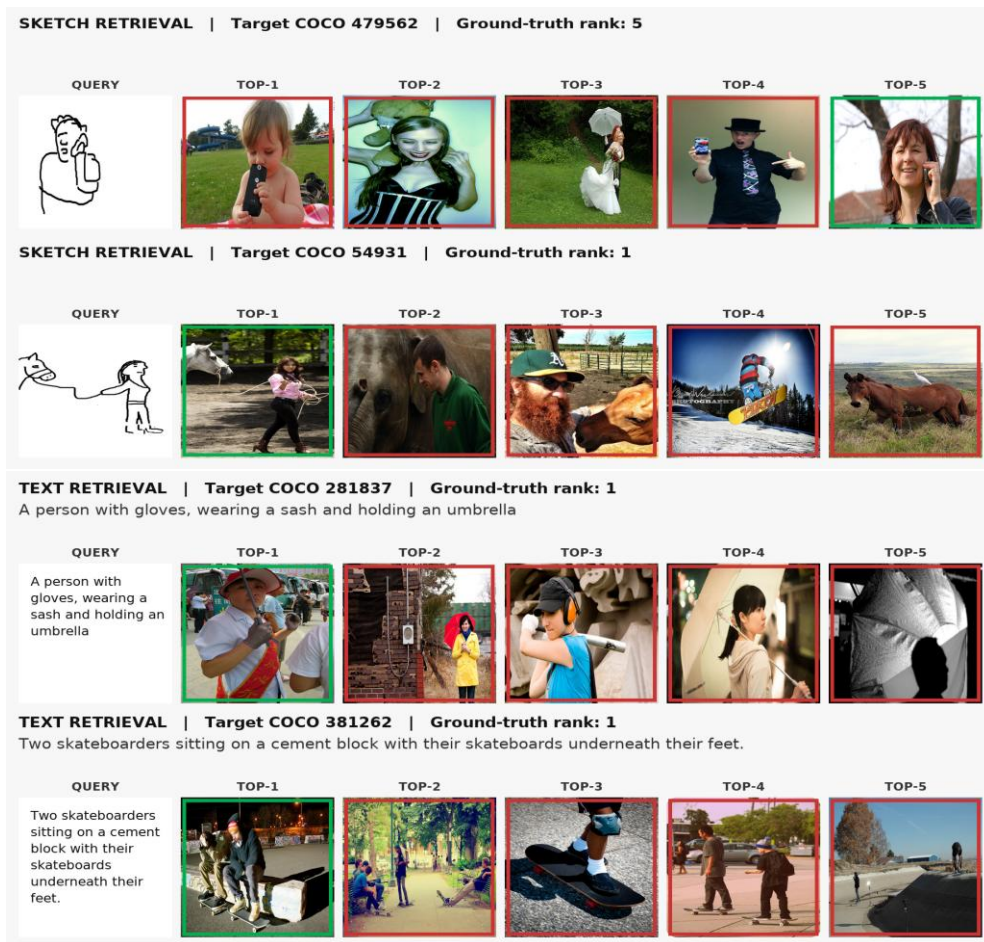
### 结果分析:

- ① 混合检索在 R@1/R@5/R@10/MRR 上均最优
- ② 文本检索本身较强, R@1 达 43.63%, 而草图检索较弱, 主要受人工草图与合成训练草图域差异影响
- ③ 相比文本检索, 混合检索 R@1 提升 5.64 个百分点, 说明草图能有效补充细粒度形状和布局信息

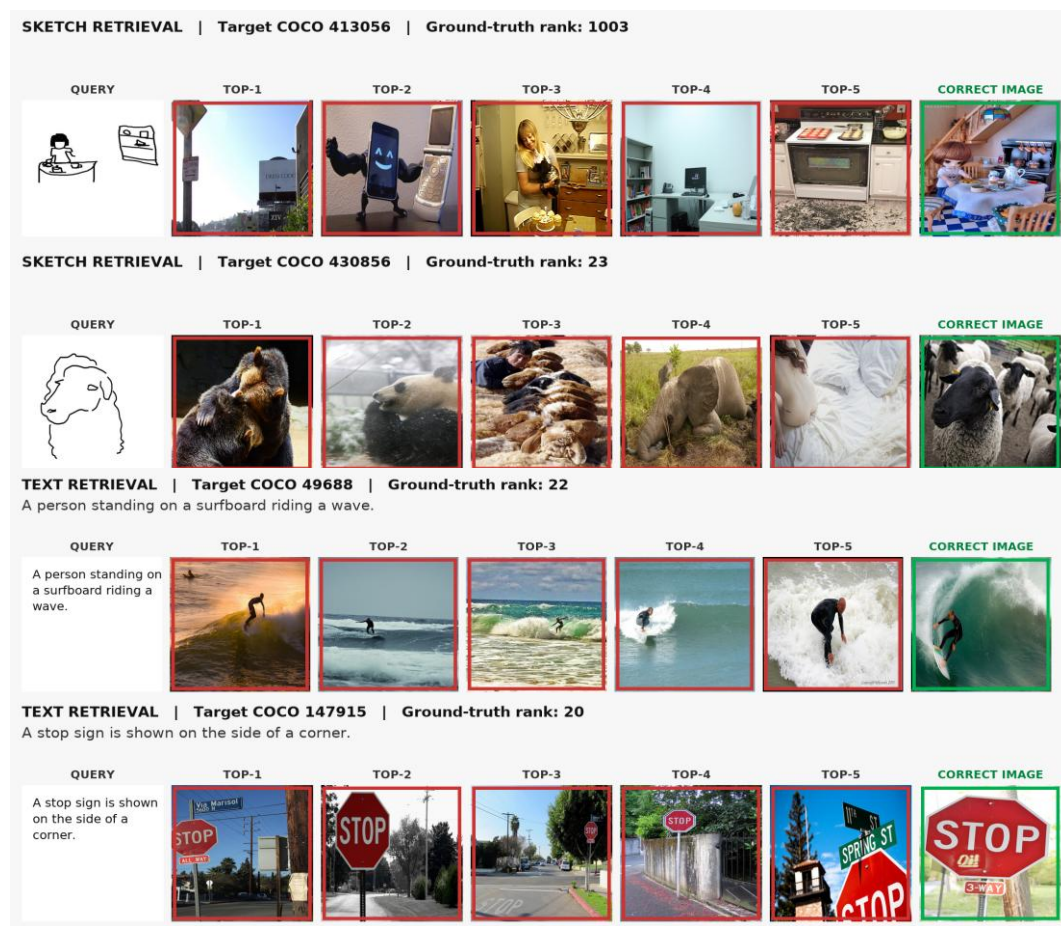


# 4. 结果评价

## 案例分析



草图或者文本检索成功案例



草图或者文本检索失败案例

- ① 草图检索在轮廓简单、类别区分明显时能命中；但当草图过于抽象或只包含局部线索时，模型容易返回形状相似但语义错误的图片
- ② 文本检索在描述明确、目标物体清晰时表现较好



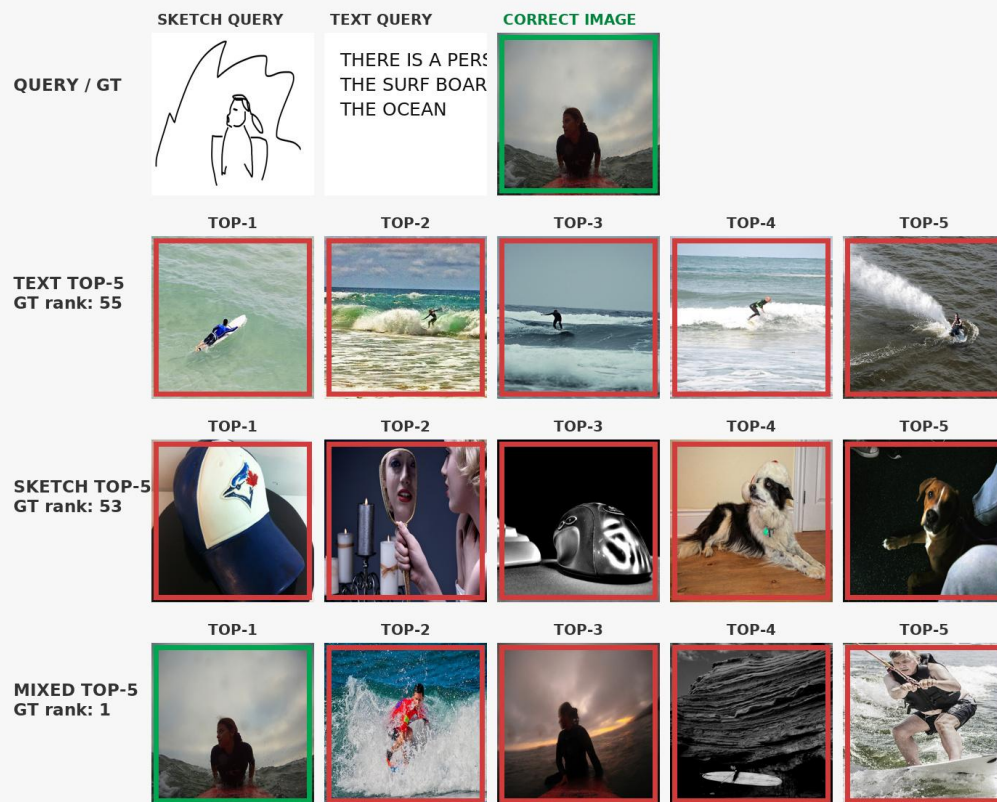


# 4. 结果评价

## 案例分析


COCO 105011 | Text rank: 55 | Sketch rank: 53 | Mixed rank: 1

THERE IS A PERSON ON THE SURF BOARD IN THE OCEAN



COCO 199346 | Text rank: 43 | Sketch rank: 107 | Mixed rank: 1

A group of people walking next to stairs.



两个样例中，Text rank 和 Sketch rank 都较低，但 Mixed rank 为 1，说明**文本可以限定语义类别**，**草图可以补充空间布局或形状细节**，二者融合可以同时利用语义和结构信息完成纠错



# 5. 分析改进

## (1) 联合训练 Gate

### 动机:

固定平均融合假设 text 和 sketch 对所有查询同样可靠, 但真实情况并非如此:

- 有的 caption 描述准确, sketch 信息较少, 应提高文本权重;
- 有的 caption 含糊, sketch 提供了形状线索, 应提高草图权重;
- 不同查询的最优融合系数可能不同。

因此, 第一个想法是用可学习 Gate 为每个查询预测独立的  $\alpha$ , 替代固定的  $\alpha = 0.5$

### 方法:

Gate 输入由文本特征、草图特征及其逐维乘积组成:

$$g = [t; s; t \odot s] \in \mathbb{R}^{3d}.$$

其中  $t \odot s$  用于显式表示两种模态的一致程度。Gate 是一个隐藏维度为 256 的两层 MLP:

$$\hat{\alpha} = \sigma(W_2 \text{GELU}(W_1 g + b_1) + b_2),$$

$$q_{\text{gate}} = \text{norm}(\hat{\alpha} t + (1 - \hat{\alpha}) s).$$



# 5. 分析改进

## (1) 联合训练 Gate

**结果：**（下文所有指标均以百分比表示，格式为 R@1 / R@5 / R@10； $\Delta$ 表示相对普通方法的百分点变化）  
Human sketch 结果对比：

| 模式     | 普通方法                  | 联合 Gate               | $\Delta$              |
|--------|-----------------------|-----------------------|-----------------------|
| Sketch | 12.60 / 24.38 / 31.66 | 11.16 / 22.64 / 29.68 | -1.44 / -1.74 / -1.98 |
| Text   | 43.63 / 72.26 / 81.92 | 43.52 / 72.44 / 82.06 | -0.12 / +0.18 / +0.14 |
| Mixed  | 49.27 / 75.86 / 85.07 | 46.96 / 73.75 / 83.05 | -2.31 / -2.11 / -2.02 |

Synthetic sketch 结果对比：

| 模式     | 普通方法                  | 联合 Gate               | $\Delta$              |
|--------|-----------------------|-----------------------|-----------------------|
| Sketch | 89.16 / 95.78 / 97.40 | 89.34 / 95.88 / 97.30 | +0.18 / +0.10 / -0.10 |
| Text   | 43.63 / 72.26 / 81.92 | 43.52 / 72.44 / 82.06 | -0.12 / +0.18 / +0.14 |
| Mixed  | 97.45 / 99.67 / 99.86 | 97.41 / 99.68 / 99.88 | -0.03 / +0.01 / +0.02 |

## 分析：

联合 Gate 没有产生预期的逐查询分化。Human mixed 模式下

$$\text{mean}(\hat{\alpha}) = 0.485, \quad \text{std}(\hat{\alpha}) = 0.023.$$

Gate 基本退化为一个接近 0.5 的固定系数。Synthetic mixed 的基线性能已接近饱和，加入 Gate 后结果基本不变；但 Human sketch 和 Human mixed 分别出现明显下降，说明当前联合训练未改善人工草图上的泛化能力。由于 Gate 与编码器同时参与优化，可能是因为联合训练改变了原有检索特征空间



# 5. 分析改进

## (2) 单独训练 Gate

**动机：**联合训练可能破坏模型已经训练好的特征空间

**方法：**直接加载普通方法的最终权重，冻结图像、文本和草图编码器以及其他参数，单独训练 Gate

**结果：** Human sketch 结果对比：

| 模式     | 普通方法                  | 单独训练 Gate             | $\Delta$              |
|--------|-----------------------|-----------------------|-----------------------|
| Sketch | 12.60 / 24.38 / 31.66 | 11.52 / 23.68 / 30.06 | -1.08 / -0.70 / -1.60 |
| Text   | 43.63 / 72.26 / 81.92 | 37.97 / 65.57 / 76.07 | -5.66 / -6.69 / -5.85 |
| Mixed  | 49.27 / 75.86 / 85.07 | 48.02 / 74.25 / 83.68 | -1.25 / -1.61 / -1.39 |

Synthetic sketch 结果对比：

| 模式     | 普通方法                  | 单独训练 Gate             | $\Delta$              |
|--------|-----------------------|-----------------------|-----------------------|
| Sketch | 89.16 / 95.78 / 97.40 | 84.26 / 93.92 / 95.96 | -4.90 / -1.86 / -1.44 |
| Text   | 43.63 / 72.26 / 81.92 | 37.97 / 65.57 / 76.07 | -5.66 / -6.69 / -5.85 |
| Mixed  | 97.45 / 99.67 / 99.86 | 97.52 / 99.69 / 99.86 | +0.08 / +0.02 / +0.00 |

**分析：**Mixed 结果仍然不理想：Synthetic R@1 仅提高 0.08 个百分点，而 Human R@1 下降 1.25 个百分点。其 Gate 输出仍接近常数：

Human mixed:  $\hat{\alpha} = 0.477 \pm 0.013$ ,

Synthetic mixed:  $\hat{\alpha} = 0.480 \pm 0.015$ .

这说明其退化并非仅由联合训练改变特征空间造成。同时，Synthetic mixed 已接近性能上限，说明Gate 在训练域中学到的融合规律难以迁移到 Human sketch，因此当前问题的重点不在于继续调整 Gate 的训练方式，而在于**缩小合成草图与人工草图之间的差异**。






# 5. 分析改进

## (3) Segment-dropout

**动机：**让数据增强后的合成草图和人工草图更加相似

**方法：**当前处理合成草图的方法是逐像素 dropout 独立删除前景像素，而人工草图的不完整性经常表现为一小段线条或一个次要结构整体缺失，先把草图骨架拆成连通笔画段，再以“段”为单位删除，从而产生更加连贯的结构缺失

两种草图 Dropout 方法对比





# 5. 分析改进

## (3) Segment-dropout

**结果：** Human sketch 结果对比：

| 模式     | 普通方法                  | Segment-dropout       | $\Delta$              |
|--------|-----------------------|-----------------------|-----------------------|
| Sketch | 12.60 / 24.38 / 31.66 | 9.98 / 20.56 / 27.34  | -2.62 / -3.82 / -4.32 |
| Text   | 43.63 / 72.26 / 81.92 | 43.92 / 72.46 / 82.35 | +0.29 / +0.20 / +0.43 |
| Mixed  | 49.27 / 75.86 / 85.07 | 46.55 / 73.41 / 82.86 | -2.72 / -2.45 / -2.21 |

Synthetic sketch 结果对比：

| 模式     | 普通方法                  | Segment-dropout       | $\Delta$                     |
|--------|-----------------------|-----------------------|------------------------------|
| Sketch | 89.16 / 95.78 / 97.40 | 90.34 / 96.70 / 97.92 | <b>+1.18 / +0.92 / +0.52</b> |
| Text   | 43.63 / 72.26 / 81.92 | 43.92 / 72.46 / 82.35 | +0.29 / +0.20 / +0.43        |
| Mixed  | 97.45 / 99.67 / 99.86 | 97.73 / 99.75 / 99.92 | +0.28 / +0.08 / +0.06        |

**分析：** Segment-dropout 提高了 Synthetic sketch 指标，但明显降低了 Human sketch 指标：

$$\Delta R@1_{\text{synthetic sketch}} = +1.18, \quad \Delta R@1_{\text{human sketch}} = -2.62.$$

这说明结构化删除本身并不能模拟完整的人工绘制分布。它能够增强模型对合成草图局部缺失的鲁棒性，但不能代表在 human sketch 泛化能力。





# 5. 分析改进

## (4) 加入 consistency-loss

### 动机:

Segment-dropout 的失败说明 synthetic-to-human 差异不是单一的整段笔画缺失，既然无法在数据处理上让合成草图和人工草图更接近，那尝试在模型上**拉近合成草图和人工草图的特征**

### 方法:

对同一 synthetic sketch 独立采样两套 human-style 风格扰动，得到  $s_1, s_2$ 。两个视图共享相同的全局 affine 和 crop，从而让一致性损失主要约束风格扰动，而不是要求编码器忽略完全不同的观察区域。设两个归一化草图特征为

$$z_1 = f_s(s_1), \quad z_2 = f_s(s_2),$$

则一致性损失为

$$\mathcal{L}_{\text{cons}} = \frac{1}{N_s} \sum_{i=1}^{N_s} \left( 1 - \frac{z_{1,i}^\top z_{2,i}}{\|z_{1,i}\|_2 \|z_{2,i}\|_2} \right).$$

只对 sketch 未被 query dropout 置空的样本计算该损失。总目标为

$$\mathcal{L}_{\text{C2}} = 100\mathcal{L}_{\text{ret}} + 10\mathcal{L}_{\text{cls}} + \mathcal{L}_{\text{dec}} + \lambda_{\text{cons}}\mathcal{L}_{\text{cons}}, \quad \lambda_{\text{cons}} = 1.$$

Consistency loss 的核心思想不是让合成草图看起来完全像人工草图，而是让模型对多种 human-style 扰动保持特征稳定。



# 5. 分析改进

## (4) 加入 consistency-loss

**结果：** Human sketch 结果对比：

| 模式     | 普通方法                  | 加入 consistency-loss   | $\Delta$                     |
|--------|-----------------------|-----------------------|------------------------------|
| Sketch | 12.60 / 24.38 / 31.66 | 14.08 / 26.64 / 33.26 | <b>+1.48 / +2.26 / +1.60</b> |
| Text   | 43.63 / 72.26 / 81.92 | 43.69 / 72.62 / 82.22 | <b>+0.06 / +0.36 / +0.30</b> |
| Mixed  | 49.27 / 75.86 / 85.07 | 50.46 / 76.60 / 85.21 | <b>+1.19 / +0.74 / +0.14</b> |

Synthetic sketch 结果对比：

| 模式     | 普通方法                  | 加入 consistency-loss   | $\Delta$                     |
|--------|-----------------------|-----------------------|------------------------------|
| Sketch | 89.16 / 95.78 / 97.40 | 90.06 / 95.70 / 97.14 | <b>+0.90 / -0.08 / -0.26</b> |
| Text   | 43.63 / 72.26 / 81.92 | 43.69 / 72.62 / 82.22 | <b>+0.06 / +0.36 / +0.30</b> |
| Mixed  | 97.45 / 99.67 / 99.86 | 97.56 / 99.68 / 99.84 | <b>+0.12 / +0.01 / -0.02</b> |

**分析：**

- ① 加入 consistency loss 后，Human 和 Human Mixed 的多项指标均有提升，说明该方法能够增强模型对人工草图变化的鲁棒性
- ② 与 Segment-dropout 不同，consistency loss 不要求模型适应某一种固定的扰动形式，而是约束同一草图经过不同 human-style 扰动后得到相近的特征表示，因此能够学习对笔画缺失、线条变形和局部结构变化更加稳定的表示
- ③ Synthetic 指标整体变化较小，说明其主要收益体现在人工草图的跨域泛化上



# 5. 分析改进

## 总结

下表列举了最能反映草图领域泛化和多模态检索能力的 R@1:

| 方法                  | Human Sketch         | Human Mixed          | Synthetic Sketch     | Synthetic Mixed      |
|---------------------|----------------------|----------------------|----------------------|----------------------|
| 普通方法                | 12.60                | 49.27                | 89.16                | 97.45                |
| 联合训练 Gate           | 11.16 (-1.44)        | 46.96 (-2.31)        | 89.34 (+0.18)        | 97.41 (-0.03)        |
| 单独训练 Gate           | 11.52 (-1.08)        | 48.02 (-1.25)        | 84.26 (-4.90)        | 97.52 (+0.08)        |
| Segment-dropout     | 9.98 (-2.62)         | 46.55 (-2.72)        | <b>90.34 (+1.18)</b> | <b>97.73 (+0.28)</b> |
| 加入 consistency-loss | <b>14.08 (+1.48)</b> | <b>50.46 (+1.19)</b> | 90.06 (+0.90)        | 97.56 (+0.12)        |

综合实验支持以下结论:

1. **当前 Gate 未能学到有效的动态融合策略。**说明当前数据和训练目标不足以使 Gate 学到有效的逐查询模态权重, 固定平均融合反而更加稳定。
2. **Synthetic 指标提升不能代表 Human 泛化能力改善。**说明针对合成草图特征进行优化, 可能只提升训练域内表现, 无法覆盖真实人工草图中的结构变化。
3. **Synthetic-to-Human 域差异是当前需要优先解决的问题。**实验并不能否定动态融合潜力, 但现阶段相比继续增加融合模块复杂度, 使用 human-style 数据增强或特征一致性约束, 更可能带来稳定的跨域提升

A series of thin, light blue wavy lines that flow from the left side of the slide, under the text, and curve upwards towards the right edge.

谢谢各位老师，欢迎批评指正